

Метод проекций в скрытые пространства: PLS, HOPLS, NLPLS

Маркин Валерий

Московский Физико-Технический Институт


Постановка задачи

Пусть задана выборка (\mathbf{X}, \mathbf{Y}) . Вместо поиска отображения $\mathbf{X}_{m \times n} \longrightarrow \mathbf{Y}_{m \times r}$, предлагается построить 2 отображения $\mathbf{X}_{m \times n} \longrightarrow \mathbf{U}_{m \times l} \longrightarrow \mathbf{Y}_{m \times r}$. Такой подход может помочь

- Алгоритм PLS находит матрицы $\mathbf{T}, \mathbf{U} \in \mathbb{R}^{m \times l}$, описывающую исходные матрицы \mathbf{X} и \mathbf{Y} . построенные матрицы удовлетворяют соотношению $\mathbf{U} = \mathbf{T}\mathbf{D} + \mathbf{H}$, где \mathbf{D} - диагональная. Метод позволяет учитывать зависимость исходной и целевой переменных.¹

$$\mathbf{X}_{m \times n} = \mathbf{T}_{m \times l} \cdot \mathbf{P}_{l \times n} + \mathbf{F}_{m \times n} = \sum_{k=1}^l \mathbf{t}_k \cdot \mathbf{p}_k + \mathbf{F}_{m \times n}, \quad (1)$$

$$\mathbf{Y}_{m \times r} = \mathbf{U}_{m \times l} \cdot \mathbf{Q}_{l \times r} + \mathbf{E}_{m \times r} = \sum_{k=1}^l \mathbf{u}_k \cdot \mathbf{q}_k + \mathbf{E}_{m \times r}. \quad (2)$$



¹Isachenko R.V., Strijov V.V. Quadratic Programming Optimization with Feature Selection for Non-linear Models // Lobachevskii Journal of Mathematics, 2018, 39(9) : 1179-1187.

Require: $\mathbf{X}, \mathbf{Y}, l$;

Ensure: $\mathbf{T}, \mathbf{P}, \mathbf{Q}$;

- 1: normalize matrices \mathbf{X} и \mathbf{Y} by columns
- 2: initialize \mathbf{u}_0 (the first column of \mathbf{Y})
- 3: $\mathbf{X}_1 = \mathbf{X}; \mathbf{Y}_1 = \mathbf{Y}$
- 4: **for** $k = 1, \dots, l$ **do**
- 5: **repeat**
- 6: $\mathbf{w}_k := \mathbf{X}_k^\top \mathbf{u}_{k-1} / (\mathbf{u}_{k-1}^\top \mathbf{u}_{k-1}); \quad \mathbf{w}_k := \frac{\mathbf{w}_k}{\|\mathbf{w}_k\|}$
- 7: $\mathbf{t}_k := \mathbf{X}_k \mathbf{w}_k$
- 8: $\mathbf{c}_k := \mathbf{Y}_k^\top \mathbf{t}_k / (\mathbf{t}_k^\top \mathbf{t}_k); \quad \mathbf{c}_k := \frac{\mathbf{c}_k}{\|\mathbf{c}_k\|}$
- 9: $\mathbf{u}_k := \mathbf{Y}_k \mathbf{c}_k$
- 10: **until** \mathbf{t}_k stabilizes
- 11: $\mathbf{p}_k := \mathbf{X}_k^\top \mathbf{t}_k / (\mathbf{t}_k^\top \mathbf{t}_k), \quad \mathbf{q}_k := \mathbf{Y}_k^\top \mathbf{t}_k / (\mathbf{t}_k^\top \mathbf{t}_k)$
- 12: $\mathbf{X}_{k+1} := \mathbf{X}_k - \mathbf{t}_k \mathbf{p}_k^\top$
- 13: $\mathbf{Y}_{k+1} := \mathbf{Y}_k - \mathbf{t}_k \mathbf{q}_k^\top$

PLS пример

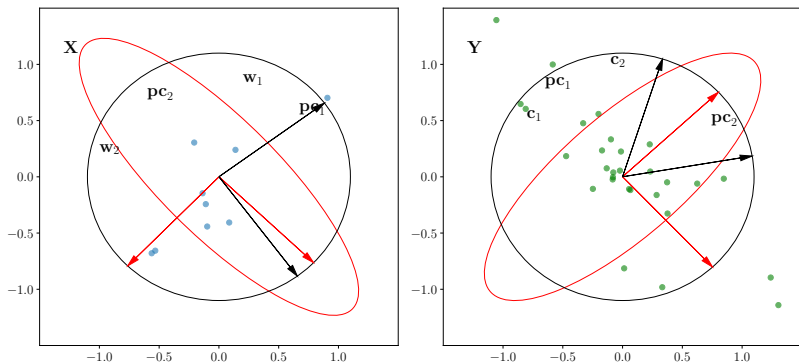


Рис.: The result of the PLS algorithm for the case $n = r = l = 2$.

Естественным является обобщение метода PLS на нелинейный случай. Есть 2 основных варианта такого обобщения

- Отображение матрицы X в нелинейное пространство. Например, строки (x_1, x_2) заменяется на (x_1^2, x_1x_2, x_2^2) . Дальнейшие действия остаются "линейными".
- Замена соотношения $\mathbf{U} = \mathbf{T}\mathbf{D} + \mathbf{H}$ на нелинейное $\mathbf{U} = F(\mathbf{T}, w) + \mathbf{H}$, где F - любая нелинейная функция, например, нейросеть.

Основная идея - переход от матриц к тензорам. Часто данные имеют многомерную структуру и для применения стандартных методов приходится превращать тензоры в матрицы, теряя ту самую структуру. Этот подход позволяет избавиться от этого недостатка.

$$\begin{aligned}\underline{\mathbf{X}} &= \sum_{r=1}^R \underline{\mathbf{G}}_r \times_1 \mathbf{t}_r \times_2 \mathbf{P}_r^{(1)} \times_3 \cdots \times_N \mathbf{P}_r^{(N-1)} + \underline{\mathbf{E}}_R \\ \underline{\mathbf{Y}} &= \sum_{r=1}^R \underline{\mathbf{D}}_r \times_1 \mathbf{t}_r \times_2 \mathbf{Q}_r^{(1)} \times_3 \cdots \times_M \mathbf{Q}_r^{(M-1)} + \underline{\mathbf{F}}_R\end{aligned}$$

Algorithm 1 The Higher-order Partial Least Squares (HOPLS)
Algorithm for a Tensor $\underline{\mathbf{X}}$ and a Tensor $\underline{\mathbf{Y}}$

Input: $\underline{\mathbf{X}} \in \mathbb{R}^{I_1 \times \dots \times I_N}$, $\underline{\mathbf{Y}} \in \mathbb{R}^{J_1 \times \dots \times J_M}$, $N \geq 3$, $M \geq 3$
and $I_1 = J_1$.

Number of latent vectors is R and number of loading
vectors are $\{L_n\}_{n=2}^N$ and $\{K_m\}_{m=2}^M$.

Output: $\{\mathbf{P}_r^{(n)}\}$; $\{\mathbf{Q}_r^{(m)}\}$; $\{\underline{\mathbf{G}}_r\}$; $\{\underline{\mathbf{D}}_r\}$; \mathbf{T}
 $r = 1, \dots, R$; $n = 1, \dots, N - 1$; $m = 1, \dots, M - 1$.

Initialization: $\underline{\mathbf{E}}_1 \leftarrow \underline{\mathbf{X}}$, $\underline{\mathbf{F}}_1 \leftarrow \underline{\mathbf{Y}}$.

for $r = 1$ **to** R **do**

if $\|\underline{\mathbf{E}}_r\|_F > \varepsilon$ **and** $\|\underline{\mathbf{F}}_r\|_F > \varepsilon$ **then**

$\underline{\mathbf{C}}_r \leftarrow \langle \underline{\mathbf{E}}_r, \underline{\mathbf{F}}_r \rangle_{\{1,1\}}$;

 Rank- $(L_2, \dots, L_N, K_2, \dots, K_M)$ orthogonal Tuck-
er decomposition of $\underline{\mathbf{C}}_r$ by HOOI [16] as

$\underline{\mathbf{C}}_r \approx [\underline{\mathbf{G}}_r^{(C_r)}; \mathbf{P}_r^{(1)}, \dots, \mathbf{P}_r^{(N-1)}, \mathbf{Q}_r^{(1)}, \dots, \mathbf{Q}_r^{(M-1)}]$;

$\mathbf{t}_r \leftarrow$ the first leading left singular vector by

$\text{SVD} \left[\left(\underline{\mathbf{E}}_r \times_2 \mathbf{P}_r^{(1)T} \times_3 \dots \times_N \mathbf{P}_r^{(N-1)T} \right)_{(1)} \right]$;

$\underline{\mathbf{G}}_r \leftarrow [\underline{\mathbf{E}}_r; \mathbf{t}_r^T, \mathbf{P}_r^{(1)T}, \dots, \mathbf{P}_r^{(N-1)T}]$;

$\underline{\mathbf{D}}_r \leftarrow [\underline{\mathbf{F}}_r; \mathbf{t}_r^T, \mathbf{Q}_r^{(1)T}, \dots, \mathbf{Q}_r^{(M-1)T}]$;

Deflation:

$\underline{\mathbf{E}}_{r+1} \leftarrow \underline{\mathbf{E}}_r - [\underline{\mathbf{G}}_r; \mathbf{t}_r, \mathbf{P}_r^{(1)}, \dots, \mathbf{P}_r^{(N-1)}]$;

$\underline{\mathbf{F}}_{r+1} \leftarrow \underline{\mathbf{F}}_r - [\underline{\mathbf{D}}_r; \mathbf{t}_r, \mathbf{Q}_r^{(1)}, \dots, \mathbf{Q}_r^{(M-1)}]$;

else

 Break;

end if

end for
